

第三章 线性方程组的数值解法（二）

——线性方程组的迭代解法

3.2 线性方程组的迭代解法

- 迭代法的基本思想
- Jacobi迭代法和Gauss-Seidel迭代法
- 迭代法的收敛性
- 超松弛迭代法
- 分块迭代法
- 极小化方法

3.2.1 迭代法的基本思想

例：求解方程组

$$\begin{cases} 8x_1 - 3x_2 + 2x_3 = 20 \\ 4x_1 + 11x_2 - x_3 = 33 \\ 6x_1 + 3x_2 + 12x_3 = 36 \end{cases}$$

其精确解是 $x^* = (3, 2, 1)^T$.

现将原方程组改写为

$$\begin{cases} x_1 = \frac{1}{8}(3x_2 - 2x_3 + 20) \\ x_2 = \frac{1}{11}(-4x_1 + x_3 + 33) \\ x_3 = \frac{1}{12}(-6x_1 - 3x_2 + 36) \end{cases}$$

简写为 $x=B_0x+f$, 其中

$$B_0 = \begin{bmatrix} 0 & \frac{3}{8} & -\frac{2}{8} \\ -\frac{4}{11} & 0 & \frac{1}{11} \\ -\frac{6}{12} & -\frac{3}{12} & 0 \end{bmatrix} \quad f = \begin{bmatrix} \frac{20}{8} \\ \frac{33}{11} \\ \frac{36}{12} \end{bmatrix}$$

任取初始值, 如取 $x^{(0)}=(0,0,0)^T$, 代入 $x=B_0x+f$ 右边, 若等式成立则求得方程组的解.

否则, 得新值 $x^{(1)}=(x_1^{(1)}, x_2^{(1)}, x_3^{(1)})^T=(2.5, 3, 3)^T$, 再将 $x^{(1)}$ 代入...

反复计算，得一向量序列 $\{x^{(k)}\}$ 和一般的计算公式（迭代公式）：

$$\begin{cases} x_1^{(k+1)} = \frac{1}{8}(3x_2^{(k)} - 2x_3^{(k)} + 20) \\ x_2^{(k+1)} = \frac{1}{11}(-4x_1^{(k)} + x_3^{(k)} + 33) \\ x_3^{(k+1)} = \frac{1}{12}(-6x_1^{(k)} - 3x_2^{(k)} + 36) \end{cases}$$

简写为 $x^{(k+1)} = B_0 x^{(k)} + f$ ($k=0,1,2,\dots$)

迭代到第10次时有

$$x^{(10)} = (3.000032, 1.999838, 0.999813)^T$$

$$\|\varepsilon^{(10)}\|_{\infty} = \|x^{(10)} - x^*\| = 0.000187$$

定义:

- (1) 对于给定方程组 $x=Bx+f$, 用迭代公式 $x^{(k+1)}=Bx^{(k)}+f$ ($k=0,1,2,\dots$) 逐步代入求近似解的方法称**迭代法**;
- (2) 若 $k \rightarrow \infty$ 时 $\lim x^{(k)}$ 存在 (记为 x^*), 称此迭代法收敛, 显然 x^* 就是方程组的解, 否则称迭代法发散;
- (3) B 称为**迭代矩阵**.

问题:

 如何建立迭代格式?

 收敛速度?

 向量序列的收敛条件?

 误差估计?

3.2.2 Jacobi迭代与 Gauss-Seidel迭代

(一) Jacobi迭代法

设 $Ax=b$, A 非奇异, 且对角元不为零, 将原方程组
改写为

$$\begin{cases} x_1 = \frac{1}{a_{11}}(b_1 - a_{12}x_2 - \cdots - a_{1n}x_n) \\ x_2 = \frac{1}{a_{22}}(b_2 - a_{21}x_1 - \cdots - a_{2n}x_n) \\ \dots\dots\dots \\ x_n = \frac{1}{a_{nn}}(b_n - a_{n1}x_1 - \cdots - a_{n,n-1}x_{n-1}) \end{cases}$$

选取初始向量 $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})$

代入上面方程组右端得 $x^{(1)} = (x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)})$

又代入，反复继续，得迭代格式：

$$\begin{cases} x_1^{(k+1)} = \frac{1}{a_{11}} (b_1 - a_{12}x_2^{(k)} - \dots - a_{1n}x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}} (b_2 - a_{21}x_1^{(k)} - \dots - a_{2n}x_n^{(k)}) \\ \dots\dots\dots \\ x_n^{(k+1)} = \frac{1}{a_{nn}} (b_n - a_{n1}x_1^{(k)} - \dots - a_{n,n-1}x_{n-1}^{(k)}) \end{cases}$$

称**Jacobi**迭代法.

Jacobi迭代法的矩阵表示:

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$



$$\begin{bmatrix} 1 & \frac{a_{12}}{a_{11}} & \cdots & \frac{a_{1n}}{a_{11}} \\ \frac{a_{21}}{a_{22}} & 1 & \cdots & \frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{a_{n1}}{a_{nn}} & \frac{a_{n2}}{a_{nn}} & \cdots & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} \frac{b_1}{a_{11}} \\ \frac{b_2}{a_{22}} \\ \vdots \\ \frac{b_n}{a_{nn}} \end{bmatrix}$$



$$I \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} + \begin{bmatrix} 0 & \frac{a_{12}}{a_{11}} & \cdots & \frac{a_{1n}}{a_{11}} \\ \frac{a_{21}}{a_{22}} & 0 & \cdots & \frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{a_{n1}}{a_{nn}} & \frac{a_{n2}}{a_{nn}} & \cdots & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} \frac{b_1}{a_{11}} \\ \frac{b_2}{a_{22}} \\ \vdots \\ \frac{b_n}{a_{nn}} \end{bmatrix}$$



$$\begin{bmatrix} x_1 \\ x_2 \\ \cdot \\ \cdot \\ \cdot \\ x_n \end{bmatrix} = - \begin{bmatrix} 0 & \frac{a_{12}}{a_{11}} & \dots & \frac{a_{1n}}{a_{11}} \\ \frac{a_{21}}{a_{22}} & 0 & \dots & \frac{a_{2n}}{a_{22}} \\ & & & \cdot \\ & & \dots & \\ \frac{a_{n1}}{a_{nn}} & \frac{a_{n2}}{a_{nn}} & & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \cdot \\ \cdot \\ \cdot \\ x_n \end{bmatrix} + \begin{bmatrix} \frac{b_1}{a_{11}} \\ \frac{b_2}{a_{22}} \\ \cdot \\ \cdot \\ \frac{b_n}{a_{nn}} \end{bmatrix}$$

矩阵表示:

$$x^{(k+1)} = B_J x^{(k)} + f_J$$

计算公式为:

$$x_i^{(k+1)} = - \frac{\sum_{j=1, j \neq i}^n a_{ij} x_j^{(k)}}{a_{ii}} + \frac{b_i}{a_{ii}} = \frac{1}{a_{ii}} [b_i - \sum_{j=1, j \neq i}^n a_{ij} x_j^{(k)}]$$

($i=1,2,\dots,n$), ($k=0,1,2,\dots$ 表迭代次数)

将方程组 $Ax=b$ 的系数矩阵 A 分解为： $A=D-L-U$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix}$$

$$(a_{ii} \neq 0)$$

$$U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ & 0 & \cdots & -a_{2n} \\ & & \ddots & \vdots \\ & & & 0 \end{bmatrix}$$

$$L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \vdots & \ddots & \\ -a_{n1} & -a_{n2} & \cdots & 0 \end{bmatrix}$$

$$x^{(k+1)} = B_J x^{(k)} + f_J$$

$$\begin{aligned} \text{则 } B_J &= I - D^{-1} A \\ &= D^{-1} (L+U), \end{aligned}$$

$$f_J = D^{-1} b,$$

称 B_J 为**Jacobi**迭代矩阵.

例1: 用Jacobi迭代法求解方程组, 误差不超过 10^{-4} .

$$\begin{pmatrix} 8 & -3 & 2 \\ 4 & 11 & -1 \\ 2 & 1 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 20 \\ 33 \\ 12 \end{pmatrix}$$

解:

$$A = \begin{pmatrix} 8 & -3 & 2 \\ 4 & 11 & -1 \\ 2 & 1 & 4 \end{pmatrix} \quad D = \begin{pmatrix} 8 & 0 & 0 \\ 0 & 11 & 0 \\ 0 & 0 & 4 \end{pmatrix}$$

$$L = \begin{pmatrix} 0 & 0 & 0 \\ -4 & 0 & 0 \\ -2 & -1 & 0 \end{pmatrix} \quad U = \begin{pmatrix} 0 & 3 & -2 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{pmatrix}$$

$$\mathbf{B}_J = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}) = \begin{pmatrix} 0 & \frac{3}{8} & -\frac{1}{4} \\ -\frac{4}{11} & 0 & \frac{1}{11} \\ -\frac{1}{2} & -\frac{1}{4} & 0 \end{pmatrix}$$

$$\mathbf{f} = \mathbf{D}^{-1}\mathbf{b} = \begin{pmatrix} 2.5 \\ 3 \\ 3 \end{pmatrix}$$

取初值 $\mathbf{x}^{(0)} = [0 \ 0 \ 0]^T$, 使用 *Jacobi* 迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{B}_J \mathbf{x}^{(k)} + \mathbf{f} \quad (k = 0, 1, 2, \dots, n, \dots)$$

$$\mathbf{x}^{(1)} = \mathbf{B}_J \mathbf{x}^{(0)} + \mathbf{f} = \begin{pmatrix} 0 & \frac{3}{8} & -\frac{1}{4} \\ -\frac{4}{11} & 0 & \frac{1}{11} \\ -\frac{1}{2} & -\frac{1}{4} & 0 \end{pmatrix} \cdot \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 2.5 \\ 3 \\ 3 \end{pmatrix}$$

$$= [2.5, 3, 3]^T \quad \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|_2 = 4.924$$

$$\mathbf{x}^{(2)} = \mathbf{B}_J \mathbf{x}^{(1)} + \mathbf{f} = \begin{pmatrix} 0 & \frac{3}{8} & -\frac{1}{4} \\ -\frac{4}{11} & 0 & \frac{1}{11} \\ -\frac{1}{2} & -\frac{1}{4} & 0 \end{pmatrix} \cdot \begin{pmatrix} 2.5 \\ 3 \\ 3 \end{pmatrix} + \begin{pmatrix} 2.5 \\ 3 \\ 3 \end{pmatrix}$$

$$= [2.875, 2.3636, 1]^T \quad \|\mathbf{x}^{(2)} - \mathbf{x}^{(1)}\|_2 = 2.1320$$

$$\mathbf{x}^{(3)} = \mathbf{B}_J \mathbf{x}^{(2)} + \mathbf{f} = \begin{pmatrix} 0 & \frac{3}{8} & -\frac{1}{4} \\ -\frac{4}{11} & 0 & \frac{1}{11} \\ -\frac{1}{2} & -\frac{1}{4} & 0 \end{pmatrix} \cdot \begin{pmatrix} 2.875 \\ 2.3636 \\ 1 \end{pmatrix} + \begin{pmatrix} 2.5 \\ 3 \\ 3 \end{pmatrix}$$

$$= [3.1364, 2.0455, 0.9716]^T \quad \|\mathbf{x}^{(3)} - \mathbf{x}^{(2)}\|_2 = 0.4127$$

依此类推,得方程组满足精度的解为 $\mathbf{x}_{12}$:

$\mathbf{x}_4 =$	3.0241	1.9478	0.9205	$d =$	0.1573
$\mathbf{x}_5 =$	3.0003	1.9840	1.0010	$d =$	0.0914
$\mathbf{x}_6 =$	2.9938	2.0000	1.0038	$d =$	0.0175
$\mathbf{x}_7 =$	2.9990	2.0026	1.0031	$d =$	0.0059
$\mathbf{x}_8 =$	3.0002	2.0006	0.9998	$d =$	0.0040
$\mathbf{x}_9 =$	3.0003	1.9999	0.9997	$d =$	7.3612e-004
$\mathbf{x}_{10} =$	3.0000	1.9999	0.9999	$d =$	2.8918e-004
$\mathbf{x}_{11} =$	3.0000	2.0000	1.0000	$d =$	1.7669e-004
$\mathbf{x}_{12} =$	3.0000	2.0000	1.0000	$d =$	3.0647e-005

迭代次数:
12次

$$\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 3.0000 \\ 2.0000 \\ 1.0000 \end{pmatrix}$$

(二) Gauss-Seidel迭代法

Jacobi迭代格式

$$\left\{ \begin{array}{l} x_1^{(k+1)} = \frac{1}{a_{11}} (b_1 - a_{12}x_2^{(k)} - \cdots - a_{1n}x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}} (b_2 - a_{21}x_1^{(k)} - \cdots - a_{2n}x_n^{(k)}) \\ \dots\dots\dots \\ x_n^{(k+1)} = \frac{1}{a_{nn}} (b_n - a_{n1}x_1^{(k)} - \cdots - a_{n,n-1}x_{n-1}^{(k)}) \end{array} \right.$$

若在迭代时尽量利用最新信息，则可将迭代格式变为

$$\left\{ \begin{array}{l} x_1^{(k+1)} = \frac{1}{a_{11}} (b_1 - a_{12}x_2^{(k)} - \cdots - a_{1n}x_n^{(k)}) \\ x_2^{(k+1)} = \frac{1}{a_{22}} (b_2 - a_{21}x_1^{(k+1)} - \cdots - a_{2n}x_n^{(k)}) \\ \dots\dots\dots \\ x_n^{(k+1)} = \frac{1}{a_{nn}} (b_n - a_{n1}x_1^{(k+1)} - \cdots - a_{n,n-1}x_{n-1}^{(k+1)}) \end{array} \right.$$

称**Gauss-Seidel**迭代法。

计算公式:

$$x_1^{(k+1)} = -\frac{1}{a_{11}} \sum_{j=2}^n a_{1j} x_j^{(k)} + \frac{1}{a_{11}} b_1$$

$$x_i^{(k+1)} = -\frac{1}{a_{ii}} \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \frac{1}{a_{ii}} \sum_{j=i+1}^n a_{ij} x_j^{(k)} + \frac{1}{a_{ii}} b_i$$

$(i=2,3,\dots,n-1)$

$$x_n^{(k+1)} = -\frac{1}{a_{nn}} \sum_{j=1}^{n-1} a_{nj} x_j^{(k+1)} + \frac{1}{a_{nn}} b_n$$

即

$$a_{ii} x_i^{(k+1)} = [b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)}]$$

$$\sum_{j=1}^i a_{ij} x_j^{(k+1)} = b_i - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \quad (i=1,2,\dots,n)$$

$$\begin{bmatrix} a_{11} & & & \\ a_{21} & a_{22} & & \\ \vdots & \vdots & \ddots & \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1^{(k+1)} \\ x_2^{(k+2)} \\ \vdots \\ x_n^{(k+1)} \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} - \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ & 0 & \ddots & \vdots \\ & & \ddots & a_{n-1,n} \\ & & & 0 \end{bmatrix} \begin{bmatrix} x_1^{(k)} \\ x_2^{(k)} \\ \vdots \\ x_n^{(k)} \end{bmatrix}$$

故 $(D - L)x^{(k+1)} = b + Ux^{(k)}$

$$x^{(k+1)} = (D - L)^{-1} Ux^{(k)} + (D - L)^{-1} b$$

Gauss-Seidel迭代格式:

$$x^{(k+1)} = B_{G-S} x^{(k)} + f_{G-S}$$

其中 $B_{G-S} = (D - L)^{-1} U$ 称 Gauss-Seidel 迭代矩阵.

例2. 用Gauss-Seidel迭代法求解例1方程组

$$\begin{pmatrix} 8 & -3 & 2 \\ 4 & 11 & -1 \\ 2 & 1 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 20 \\ 33 \\ 12 \end{pmatrix}$$

要求误差仍然不超过 10^{-4} .

解: Gauss-Seidel迭代格式为

$$\begin{cases} x_1^{(k+1)} = \frac{1}{8}(3x_2^{(k)} - 2x_3^{(k)}) + 2.5 \\ x_2^{(k+1)} = \frac{1}{11}(-4x_1^{(k+1)} + x_3^{(k)}) + 3 \\ x_3^{(k+1)} = \frac{1}{4}(-2x_1^{(k+1)} - x_2^{(k+1)}) + 3 \end{cases}$$

取初值 $x^{(0)}=(0,0,0)^T$ 通过迭代，至第7步得到满足精度的解 x_7 ：

x_1	=2.5000	2.0909	1.2273	$d=3.4825$
x_2	=2.9773	2.0289	1.0041	$d=0.5305$
x_3	=3.0098	1.9968	0.9959	$d=0.0465$
x_4	=2.9998	1.9997	1.0002	$d=0.0112$
x_5	=2.9998	2.0001	1.0001	$d=3.9735e-004$
x_6	=3.0000	2.0000	1.0000	$d=1.9555e-004$
x_7	=3.0000	2.0000	1.0000	$d=1.1576e-005$

从例1和例2可以看出， Gauss—Seidel迭代法的收敛速度比Jacobi迭代法要快。

Jacobi迭代法和Gauss—Seidel迭代法统称为简单迭代法。

3.2.3 迭代法的收敛性

设求解线性方程组的迭代格式为

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{B}\boldsymbol{x}^{(k)} + \boldsymbol{f}$$

而方程组的精确解为 $\boldsymbol{x}^*$, 则

$$\boldsymbol{x}^* = \boldsymbol{B}\boldsymbol{x}^* + \boldsymbol{f}$$

将上面两式相减,得

$$\boldsymbol{x}^{(k+1)} - \boldsymbol{x}^* = \boldsymbol{B}(\boldsymbol{x}^{(k)} - \boldsymbol{x}^*)$$

$$\text{令 } \boldsymbol{\varepsilon}^{(k)} = \boldsymbol{x}^{(k)} - \boldsymbol{x}^* \quad k = 0, 1, 2, \dots$$

$$\text{则 } \boldsymbol{\varepsilon}^{(k+1)} = B\boldsymbol{\varepsilon}^{(k)} = B^2\boldsymbol{\varepsilon}^{(k-1)} = \dots = B^{k+1}\boldsymbol{\varepsilon}^{(0)}$$

注意 $\boldsymbol{\varepsilon}^{(0)} = \boldsymbol{x}^{(0)} - \boldsymbol{x}^*$ 为非零常数向量

因此迭代法收敛的充要条件

$$\lim_{k \rightarrow \infty} \boldsymbol{\varepsilon}^{(k+1)} = \lim_{k \rightarrow \infty} (\boldsymbol{x}^{(k+1)} - \boldsymbol{x}^*) = \mathbf{0}$$

可转变为

$$\lim_{k \rightarrow \infty} B^{k+1} = \mathbf{0}$$

引理： 迭代格式 $\boldsymbol{x}^{(k+1)} = B\boldsymbol{x}^{(k)} + \boldsymbol{f}$

收敛的充要条件为 $\lim_{k \rightarrow \infty} B^k = \mathbf{0}$.

定理：迭代格式 $x^{(k+1)} = Bx^{(k)} + f$

收敛的充要条件为 **迭代矩阵的谱半径** $\rho(B)<1$.

证：对任何 n 阶矩阵 B ，都存在非奇矩阵 P ，使

$$B = P^{-1} J P$$

其中， J 为 B 的 Jordan 标准型。

$$J = \begin{pmatrix} J_1 & & \\ & J_2 & \\ & & \ddots \\ & & & J_r \end{pmatrix}_{n \times n} \quad \text{其中, } J_i \text{ 为 Jordan 块}$$
$$J_i = \begin{bmatrix} \lambda_i & 1 & \\ & \ddots & 1 \\ & & \lambda_i \end{bmatrix}_{n_i \times n_i}$$

其中 λ_i 是矩阵 B 的特征值, 由 $B = P^{-1} J P$

$$B^k = (P^{-1} J P) (P^{-1} J P) \cdots (P^{-1} J P) = P^{-1} J^k P$$

迭代法 $x^{(k+1)} = B x^{(k)} + f$ 收敛 $\Leftrightarrow \lim_{k \rightarrow \infty} B^k = 0$

$$\Leftrightarrow \lim_{k \rightarrow \infty} J^k = 0$$

$$\Leftrightarrow \lim_{k \rightarrow \infty} \lambda_i^k = 0 \quad (i = 1, 2, \cdots, r)$$

$$\Leftrightarrow |\lambda_i| < 1 \quad (i = 1, 2, \cdots, r)$$

$$\Leftrightarrow \max_{1 \leq i \leq r} |\lambda_i| < 1 \quad \Leftrightarrow \text{谱半径 } \rho(B) < 1$$

推论 若 $\|B\|<1$, 则迭代法 $x^{(k+1)} = B x^{(k)} + f$ 收敛.

(因为 $\rho(B)\leq \|B\|$)

定理: 设 x^* 为方程组 $Ax=b$ 的解, 若 $\|B\|<1$, 则对迭代格式 $x^{(k+1)} = B x^{(k)} + f$, 有

$$(1) \quad \|x^{(k)} - x^*\| \leq \frac{\|B\|}{1 - \|B\|} \|x^{(k)} - x^{(k-1)}\|$$

$$(2) \quad \|x^{(k)} - x^*\| \leq \frac{\|B\|^k}{1 - \|B\|} \|x^{(1)} - x^{(0)}\|$$

证 由 $\|B\| < 1$, 有 $\lim_{k \rightarrow \infty} x^{(k)} = x^*$

$$x^{(k+1)} - x^* = (Bx^{(k)} + f) - (Bx^* + f) = B(x^{(k)} - x^*)$$

$$\|x^{(k+1)} - x^*\| \leq \|B\| \|x^{(k)} - x^*\|$$

所以

$$\begin{aligned} \|x^{(k)} - x^*\| &= \|(x^{(k)} - x^{(k+1)}) + (x^{(k+1)} - x^*)\| \\ &\leq \|x^{(k)} - x^{(k+1)}\| + \|x^{(k+1)} - x^*\| \\ &\leq \|x^{(k)} - x^{(k+1)}\| + \|B\| \|x^{(k)} - x^*\| \\ &= \|x^{(k+1)} - x^{(k)}\| + \|B\| \|x^{(k)} - x^*\| \end{aligned}$$

所以 $\| \mathbf{x}^{(k)} - \mathbf{x}^* \| \leq \frac{1}{1 - \| \mathbf{B} \|} \| \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} \|$

$$\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} = (\mathbf{B}\mathbf{x}^{(k)} - \mathbf{f}) - (\mathbf{B}\mathbf{x}^{(k-1)} - \mathbf{f}) = \mathbf{B}(\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)})$$

$$\| \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} \| \leq \| \mathbf{B} \| \| \mathbf{x}^{(k)} - \mathbf{x}^{(k-1)} \|$$

故可得误差估计式:

$$\| \mathbf{x}^{(k)} - \mathbf{x}^* \| \leq \frac{\| \mathbf{B} \|}{1 - \| \mathbf{B} \|} \| \mathbf{x}^{(k)} - \mathbf{x}^{(k-1)} \|$$

$$\| \mathbf{x}^{(k)} - \mathbf{x}^* \| \leq \frac{\| \mathbf{B} \|^k}{1 - \| \mathbf{B} \|} \| \mathbf{x}^{(1)} - \mathbf{x}^{(0)} \|$$

注:

$$(1) \text{ 式 } \|x^{(k)} - x^*\| \leq \frac{\|B\|}{1 - \|B\|} \|x^{(k)} - x^{(k-1)}\|$$

说明, 只要 $\|B\|$ 不是很接近 1, 当 $x^{(k)}$ 和 $x^{(k-1)}$ 很接近时, $x^{(k)}$ 也越接近 x^* , 故可用 $\|x^{(k)} - x^{(k-1)}\|$ 中止迭代.

$$(2) \text{ 式 } \|x^{(k)} - x^*\| \leq \frac{\|B\|^k}{1 - \|B\|} \|x^{(1)} - x^{(0)}\|$$

说明, $\|B\|$ 越小, $x^{(k)}$ 收敛越快, 可作误差估计式.

例3. 判别下列方程组用Jacobi迭代法和Gauss-Seidel迭代法求解是否收敛:

$$\begin{pmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

解: (1) Jacobi迭代法的迭代矩阵

$$\begin{aligned} B_J = D^{-1}(L + U) &= \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 0 & -2 & 2 \\ -1 & 0 & -1 \\ -2 & -2 & 0 \end{pmatrix} \\ &= \begin{pmatrix} 0 & -2 & 2 \\ -1 & 0 & -1 \\ -2 & -2 & 0 \end{pmatrix} \end{aligned}$$

显然 B_J 的几种常用算子范数 $\|B_J\|>1$, 故用其特征值判断.

$$\det(\lambda I - B_J) = \det \begin{pmatrix} \lambda & 2 & -2 \\ 1 & \lambda & 1 \\ 2 & 2 & \lambda \end{pmatrix} = \lambda^3 = 0$$

$$\text{所以 } \lambda = 0 \quad \rho(B_J) = \max(|\lambda|) = 0 < 1$$

即Jacobi迭代法收敛.

(2) Gauss-Seidel迭代法的迭代矩阵:

$$B_G = (D - L)^{-1} U = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 2 & 2 & 1 \end{pmatrix}^{-1} \cdot \begin{pmatrix} 0 & -2 & 2 \\ 0 & 0 & -1 \\ 0 & 0 & 0 \end{pmatrix}$$

$$B_G = \begin{pmatrix} 0 & -2 & 2 \\ 0 & 2 & -3 \\ 0 & 0 & 2 \end{pmatrix} \quad \text{可得} \quad \lambda = 0 \quad \lambda = 2$$

故 $\rho(B_G) = \max(|\lambda|) = 2 > 1$

所以Gauss-Seidel迭代法发散.

注：在例1和例2中，Gauss-Seidel迭代法收敛速度比Jacobi迭代法要高，但例3却说明Gauss-Seidel迭代法发散时而Jacobi迭代法却收敛，因此，不能说Gauss-Seidel迭代法比Jacobi迭代法更好.

迭代法收敛的其他结论:

定义 设 $A=(a_{ij})_{n \times n} \in R^{n \times n}$, 若

$$|a_{ii}| \geq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \quad (i=1,2,\dots,n)$$

称 A 为 **对角占优矩阵**, 若不等式严格成立,
则称 A 为 **严格对角占优矩阵**.

定理 若矩阵 A 是严格对角占优矩阵, 则 A 是非奇异矩阵.

证明: 只需要证明 $Ax=0$ 只有零解即可. 可用反证法.

设方程组有非零解 $x \neq 0$, 则 x 的各分量不全为零, 不妨设

$$|x_k| = \max_{1 \leq i \leq n} |x_i|$$

显然 $x_k \neq 0$, 考虑方程组 $Ax=0$ 的第 k 行,

$$\sum_{j=1}^n a_{kj} x_j = 0$$

即

$$a_{kk} x_k = - \sum_{\substack{j=1 \\ j \neq k}}^n a_{kj} x_j$$

可得

$$\begin{aligned} |a_{kk}| |x_k| &= \left| \sum_{\substack{j=1 \\ j \neq k}}^n a_{kj} x_j \right| \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj} x_j| \\ &\leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}| \left(\max_{1 \leq j \leq n} |x_j| \right) = |x_k| \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}| \end{aligned}$$

由于 $x_k \neq 0$, 故

$$|a_{kk}| \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}|$$

与 A 为严格对角占优矩阵矛盾, 故 A 为非奇异矩阵.

定理 若 $Ax=b$ 中 A 为严格对角占优矩阵, 则Jacobi迭代法和Gauss-Seidel迭代法均收敛.

证明: 因为系数矩阵 A 严格对角占优, 所以

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad i = 1, 2, 3, \dots, n$$

$$\frac{1}{|a_{ii}|} \sum_{j \neq i} |a_{ij}| < 1 \quad i = 1, 2, 3, \dots, n$$

(1)对于Jacobi迭代法, 其迭代矩阵为 $B_J = D^{-1}(L+U)$

$$B_J = - \begin{pmatrix} \mathbf{0} & \frac{a_{12}}{a_{11}} & \dots & \frac{a_{1n}}{a_{11}} \\ \frac{a_{21}}{a_{22}} & \mathbf{0} & \dots & \frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{a_{n1}}{a_{nn}} & \frac{a_{n2}}{a_{nn}} & \dots & \mathbf{0} \end{pmatrix}$$

$$\|B_J\|_{\infty} = \max_i \frac{1}{|a_{ii}|} \sum_{j \neq i} |a_{ij}| < 1$$

故Jacobi迭代法收敛.

(2)对于G—S迭代法，其迭代矩阵为 $B_G = (D - L)^{-1}U$

分析：要证G—S迭代法收敛，即证其迭代矩阵的谱半径 $\rho(B) < 1$ ，只要证明其特征值 $|\lambda| < 1$ 即可.

B_G 的特征值 λ 满足 $\det(\lambda I - B_G) = 0$

即 $\det[\lambda I - (D - L)^{-1}U] = 0$

从而

$$\det(D - L)^{-1} \cdot \det[\lambda(D - L) - U] = 0$$

因此

$$\det[\lambda(D - L) - U] = 0$$

<以下用反证法> 由于 $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$

可得 $|\lambda| \cdot |a_{ii}| > |\lambda| \cdot \sum_{j=1}^{i-1} |a_{ij}| + |\lambda| \cdot \sum_{j=i+1}^n |a_{ij}|$

$$= |\lambda| \cdot \sum_{j=1}^{i-1} |a_{ij}| + \sum_{j=i+1}^n |a_{ij}| + (|\lambda| - 1) \cdot \sum_{j=i+1}^n |a_{ij}|$$

如果 $|\lambda| \geq 1$, 则有

$$|\lambda| \cdot |a_{ii}| > |\lambda| \cdot \sum_{j=1}^{i-1} |a_{ij}| + \sum_{j=i+1}^n |a_{ij}|$$

则 $[\lambda(D - L) - U]$ 为严格对角占优矩阵

从而 $\det[\lambda(D - L) - U] \neq 0$ 矛盾!

所以 $|\lambda| < 1$, 即 $\rho(B_G) < 1$,

由前述定理知, G-S迭代法收敛.

定理 若 A 为对称正定矩阵, 则Gauss-Seidel迭代法收敛.

证明: 由 $A = D - L - L^T$ 得 $B_{G-S} = (D - L)^{-1}L^T$

设 λ 为 B_{G-S} 的任一特征值, x 为其特征向量, 则

$$(D - L)^{-1} L^T x = \lambda x \quad \Longrightarrow \quad L^T x = \lambda(D - L)x$$

$$\Longrightarrow \quad x^T L^T x = \lambda x^T (D - L)x$$

$$\text{记 } x^T D x = p, \quad x^T L^T x = x^T L x = a, \quad (Lx, x) = (x, Lx)$$

因 A 正定, $a_{ii} > 0$, 故 $p > 0$, 且有

$$x^T A x = x^T (D - L - L^T) x = p - a - a = p - 2a > 0$$

$$\lambda = \frac{x^T L^T x}{x^T (D - L)x} = \frac{a}{p - a}$$

$$\lambda^2 = \frac{a^2}{p^2 - 2pa + a^2} = \frac{a^2}{p(p - 2a) + a^2} < 1$$

所以，迭代矩阵 B_{G-S} 的谱半径 $\rho(B_{G-S}) < 1$,

故当方程组 $Ax=b$ 的系数矩阵 A 是对称正定矩阵时，Gauss-Seidel 迭代法收敛。

3.2.4 超松弛迭代法 (SOR)

——迭代法的加速

考虑解线性方程组的Gauss-Seidel迭代法

$$\begin{aligned}x_i^{(k+1)} &= -\frac{1}{a_{ii}} \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \frac{1}{a_{ii}} \sum_{j=i+1}^n a_{ij} x_j^{(k)} + \frac{1}{a_{ii}} b_i \\&= \frac{1}{a_{ii}} b_i - \frac{1}{a_{ii}} \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \frac{1}{a_{ii}} \sum_{j=i+1}^n a_{ij} x_j^{(k)} \\&= \frac{1}{a_{ii}} b_i - \frac{1}{a_{ii}} \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \frac{1}{a_{ii}} \sum_{j=i}^n a_{ij} x_j^{(k)} + x_i^{(k)} \\&= x_i^{(k)} + \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right)\end{aligned}$$

$$\begin{aligned}
 \text{令 } r_i^{(k)} &= x_i^{(k+1)} - x_i^{(k)} \\
 &= \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right)
 \end{aligned}$$

$r_i^{(k)}$ 为第 $k+1$ 次迭代时 x_i 的改变量

$$\text{因此 } x_i^{(k+1)} = x_i^{(k)} + r_i^{(k)}$$

在改变量 $r_i^{(k)}$ 前加一个因子 ω , ($0 < \omega < 2$), 得

$$\begin{aligned}
 x_i^{(k+1)} &= x_i^{(k)} + \omega r_i^{(k)} \\
 &= x_i^{(k)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right)
 \end{aligned}$$

在上式中合并 $x_i^{(k)}$,得

$$x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \frac{\omega}{a_{ii}}(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)})$$

$$i = 1, 2, \dots, n, \quad k = 0, 1, 2, \dots$$

上式称为**逐次超松弛法(SOR迭代法)**, ω 称为松弛因子

下面推导SOR迭代法的矩阵形式:

由G-S迭代法的矩阵形式

$$\begin{aligned} x^{(k+1)} &= B_{G-S} x^{(k)} + f_{G-S} \\ &= (D - L)^{-1} U x^{(k)} + (D - L)^{-1} b \end{aligned}$$

得 $(D - L)x^{(k+1)} = Ux^{(k)} + b$

$$Dx^{(k+1)} = Lx^{(k+1)} + Ux^{(k)} + b$$

故

$$\begin{aligned} x^{(k+1)} &= D^{-1}Lx^{(k+1)} + D^{-1}Ux^{(k)} + D^{-1}b \\ &= x^{(k)} - x^{(k)} + D^{-1}Lx^{(k+1)} + D^{-1}Ux^{(k)} + D^{-1}b \end{aligned}$$

记 $r^{(k)} = x^{(k+1)} - x^{(k)}$

(第 $k + 1$ 次迭代时 x 的改变量)

$$= -x^{(k)} + D^{-1}Lx^{(k+1)} + D^{-1}Ux^{(k)} + D^{-1}b$$

则SOR迭代即为

$$\begin{aligned} \mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} + \omega \mathbf{r}^{(k)} \quad \text{在 } \mathbf{r}^{(k)} \text{ 前加上因子 } \omega \\ &= (1 - \omega) \mathbf{x}^{(k)} + \omega (D^{-1} L \mathbf{x}^{(k+1)} + D^{-1} U \mathbf{x}^{(k)} + D^{-1} \mathbf{b}) \end{aligned}$$

两边同时左乘 D ，可得

$$D \mathbf{x}^{(k+1)} = (1 - \omega) D \mathbf{x}^{(k)} + \omega (L \mathbf{x}^{(k+1)} + U \mathbf{x}^{(k)} + \mathbf{b})$$

$$(D - \omega L) \mathbf{x}^{(k+1)} = ((1 - \omega) D + \omega U) \mathbf{x}^{(k)} + \omega \mathbf{b}$$

即

$$\mathbf{x}^{(k+1)} = (D - \omega L)^{-1} ((1 - \omega) D + \omega U) \mathbf{x}^{(k)} + \omega (D - \omega L)^{-1} \mathbf{b}$$

$$\text{令 } B_{\omega} = (D - \omega L)^{-1} ((1 - \omega)D + \omega U)$$

$$f_{\omega} = \omega(D - \omega L)^{-1} b$$

$$x^{(k+1)} = B_{\omega} x^{(k)} + f_{\omega}$$

上式为逐次超松弛法(SOR迭代法)的矩阵形式.

B_{ω} 为SOR法的迭代矩阵

当 $\omega=1$ 时, SOR法化为

$$x^{(k+1)} = (D - L)^{-1} Ux^{(k)} + (D - L)^{-1} b \quad \text{G-S迭代法}$$

故G-S法为SOR法的特例, SOR法为G-S法的加速.

例1. 用G—S法和SOR法求下列方程组的解:

(取 $\omega = 1.45$)

$$\begin{pmatrix} 4 & -2 & -1 \\ -2 & 4 & -2 \\ -1 & -2 & 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 0 \\ -2 \\ 3 \end{pmatrix}$$

(要求精度 $\varepsilon = 10^{-6}$)

解： (1) G—S迭代法

$$\begin{aligned} B_{G-S} &= (D - L)^{-1} U = \begin{pmatrix} 4 & 0 & 0 \\ -2 & 4 & 0 \\ -1 & -2 & 3 \end{pmatrix}^{-1} \begin{pmatrix} 0 & 2 & 1 \\ 0 & 0 & 2 \\ 0 & 0 & 0 \end{pmatrix} \\ &= \begin{pmatrix} 0 & 0.5 & 0.25 \\ 0 & 0.25 & 0.625 \\ 0 & 1/3 & 0.5 \end{pmatrix} \\ f_{G-S} &= (D - L)^{-1} b = \begin{pmatrix} 4 & 0 & 0 \\ -2 & 4 & 0 \\ -1 & -2 & 3 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ -2 \\ 3 \end{pmatrix} = \begin{pmatrix} 0 \\ -0.5 \\ 2/3 \end{pmatrix} \end{aligned}$$

取初值 $x^{(0)} = (1, 1, 1)^T$

x_1	x_2	x_3	
1	1	1	满足精度的解
0.7500000	0.3750000	1.5000000	
0.5625000	0.5312500	1.5416667	
0.6510417	0.5963542	1.6145833	
0.7018229	0.6582031	1.6727431	
.....			
0.9999933	0.9999923	1.9999926	迭代次数为71次
0.9999943	0.9999935	1.9999937	
0.9999952	0.9999944	1.9999946	
$k = 71$			

(2) SOR迭代法

取 $\omega = 1.45$

$$x^{(k+1)} = (D - \omega L)^{-1} ((1 - \omega)D + \omega U)x^{(k)} + \omega(D - \omega L)^{-1} b$$

x_1	x_2	x_3
1	1	1
0.6375000	0.0121875	1.3199063
0.2004270	0.3717572	1.3122805
0.6550335	0.5340119	1.6922848
0.7058468	0.7733401	1.7771932
.....		
0.9999990	0.9999976	1.9999991
0.9999984	0.9999993	1.9999989
0.9999998	0.9999994	1.9999998
0.9999996	0.9999998	1.9999997
$k = 24$		

满足精度的解

$x =$

1.000000

1.000000

2.000000

迭代次数为 24 次

注：选取适当的 ω ，SOR法的收敛速度比G-S法要快得多。

但是，松弛因子的选取是很困难的，一般采用**试算**进行。

SOR迭代法收敛条件的判定:

定理1 SOR收敛的充要条件是 $\rho(B\omega) < 1$.

定理2 (SOR收敛的必要条件) 设解线性方程组 $Ax=b$ 的SOR迭代法收敛, 则 $0 < \omega < 2$.

定理2说明: 解 $Ax=b$ 的SOR迭代法只有在 $(0,2)$ 内取松弛因子 ω , 才可能收敛.

定理3 已知线性方程组 $Ax=b$ ，如果

1) A 为对称正定；

2) $0<\omega<2$.

则求解 $Ax=b$ 的SOR迭代法收敛.

定理4 已知线性方程组 $Ax=b$ ，如果

1) A 为严格对角占优矩阵；

2) $0<\omega\leq 1$.

则解 $Ax=b$ 的SOR迭代法收敛.

3.2.5 分块迭代法

设 $A \in R^{n \times n}$, $x \in R^n$, $b \in R^n$,

将方程组 $Ax = b$ 中系数矩阵 A 、右端向量 b 、未知向量 x 分块, 得

$$\begin{bmatrix} A_{11} & A_{12} & \cdots & A_{1r} \\ A_{21} & A_{22} & \cdots & A_{2r} \\ \cdots & \cdots & \cdots & \cdots \\ A_{r1} & A_{r2} & \cdots & A_{rr} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_r \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_r \end{bmatrix}$$

其中, $A_{ii} \in R^{n_i \times n_i}$, $A_{ij} \in R^{n_i \times n_j}$, $x_i \in R^{n_i}$, $b_i \in R^{n_i}$

将 A 分解, $A = D_B - L_B - U_B$, 其中

$$D_B = \begin{bmatrix} A_{11} & & & \\ & A_{22} & & \\ & & \ddots & \\ & & & A_{rr} \end{bmatrix}$$

$$L_B = \begin{bmatrix} 0 & & & \\ -A_{21} & 0 & & \\ & & \ddots & \\ -A_{r1} & -A_{r2} & \cdots & 0 \end{bmatrix}$$

$$U_B = \begin{bmatrix} 0 & -A_{12} & \cdots & -A_{1r} \\ & 0 & \cdots & -A_{2r} \\ & & \ddots & \cdots \\ & & & 0 \end{bmatrix}$$

(1) 块Jacobi迭代法 (BJ)

$$D_B x^{(k+1)} = (L_B + U_B)x^{(k)} + b$$

由分块矩阵乘法，得到块Jacobi迭代法的具体形式：

$$A_{ii} x_i^{(k+1)} = b_i - \sum_{j \neq i} A_{ij} x_j^{(k)} \quad i=1,2,\cdots, r$$

(2)块Gauss-Seidel迭代法

$$D_B \mathbf{x}^{(k+1)} = L_B \mathbf{x}^{(k+1)} + U_B \mathbf{x}^{(k)} + \mathbf{b}$$

块Gauss-Seidel迭代法的具体形式：

$$A_{ii} \mathbf{x}_i^{(k+1)} = \mathbf{b}_i - \sum_{j=1}^{i-1} A_{ij} \mathbf{x}_j^{(k+1)} - \sum_{j=i+1}^r A_{ij} \mathbf{x}_j^{(k)}$$

$$i=1,2,\cdots, r$$

(3) 块SOR迭代法 (BSOR)

$$\mathbf{x}^{(k+1)} = B_{\omega} \mathbf{x}^{(k)} + \mathbf{f}$$

其中 $B_{\omega} = (D_B - \omega L_B)^{-1} ((1 - \omega)D_B + \omega U_B)$

$$\mathbf{f}_{\omega} = \omega(D_B - \omega L_B)^{-1} \mathbf{b}$$

块SOR迭代法的具体形式

$$A_{ii} \mathbf{x}_i^{(k+1)} = A_{ii} \mathbf{x}_i^{(k)} + \omega(b_i - \sum_{j=1}^{i-1} A_{ij} \mathbf{x}_j^{(k+1)} - \sum_{j=i+1}^r A_{ij} \mathbf{x}_j^{(k)})$$

$i=1, 2, \dots, r$, ω 为松弛因子.

3.2.6 极小化方法

- 与线性方程组等价的变分问题
- 最速下降法
- 共轭梯度法(CG)
- 预条件共轭梯度法(PCG)

与线性方程组等价的变分问题:

设 $x, y \in \mathbb{R}^n$, 记 $(x, y) = x^T y$

- $(x, y) = (y, x)$;
- $(tx, y) = t(x, y)$;
- $(x + y, z) = (x, z) + (y, z)$;
- $(x, x) \geq 0$, 且 $(x, x) = 0 \Leftrightarrow x = 0$;

设 A 是 n 阶对称正定阵

- $(Ax, y) = (x, Ay)$;
- $(Ax, x) \geq 0$, 且 $(Ax, x) = 0 \Leftrightarrow x = 0$

设 A 是 n 阶对称正定矩阵，求解的线性方程组为

$$Ax = b \quad (1)$$

其中 $A = (a_{ij}) \in R^{n \times n}$, $x = (x_1, x_2, \dots, x_n)^T$, $b = (b_1, b_2, \dots, b_n)^T$

对应的二次函数 $\varphi : R^{n \times n} \rightarrow R$ ，称为模函数，定义为

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i \quad (2)$$

例

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 6 \end{bmatrix}, \quad b = \begin{bmatrix} 4 \\ 10 \end{bmatrix}$$

$$\varphi(x) = \frac{1}{2}(x_1^2 + 6x_2^2 + 4x_1x_2) - (4x_1 + 10x_2)$$

模函数有如下性质：

$$\varphi(x) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i$$

(1) 对一切 $x \in R^n$, 有 $\nabla \varphi(x) = \text{grad} \varphi(x) = Ax - b = -r$ (3)

证：
$$\frac{\partial \varphi}{\partial x_i} = \sum_{j=1}^n a_{ij} x_j - b_i = -r_i, \quad i = 1, 2, \dots, n$$

$$\text{grad} \varphi(x) = \left[\frac{\partial \varphi}{\partial x_1} \quad \dots \quad \frac{\partial \varphi}{\partial x_n} \right]^T = Ax - b = -r$$

例

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 6 \end{bmatrix}, \quad b = \begin{bmatrix} 4 \\ 10 \end{bmatrix}$$

$$\varphi(x) = \frac{1}{2} (x_1^2 + 6x_2^2 + 4x_1 x_2) - (4x_1 + 10x_2)$$

$$\frac{\partial \varphi}{\partial x_1} = x_1 + 2x_2 - 4 = -r_1, \quad \frac{\partial \varphi}{\partial x_2} = 2x_1 + 6x_2 - 10 = -r_2$$

(2) 对一切 $x, y \in R^n, \alpha \in R$

$$\varphi(x + \alpha y) = \varphi(x) + \alpha(Ax - b, y) + \frac{\alpha^2}{2}(Ay, y) \quad (4)$$

$$\begin{aligned} \text{证: } \varphi(x + \alpha y) &= \frac{1}{2}(A(x + \alpha y), x + \alpha y) - (b, x + \alpha y) \\ &= \frac{1}{2}(Ax, x) - (b, x) + \alpha(Ax, y) - \alpha(b, y) + \frac{\alpha^2}{2}(Ay, y) \\ &= \varphi(x) + \alpha(Ax - b, y) + \frac{\alpha^2}{2}(Ay, y) \end{aligned}$$

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x)$$

(3) 设 x^* 为 $Ax=b$ 的解, 则

$$\text{对一切 } x \in R^n, \text{ 有 } \varphi(x) - \varphi(x^*) = \frac{1}{2}(A(x - x^*), x - x^*) \quad (5)$$

$$\text{证: 由 } \varphi(x^*) = -\frac{1}{2}(b, A^{-1}b) = -\frac{1}{2}(Ax^*, x^*)$$

$$\varphi(x^*) = \frac{1}{2}(Ax^*, x^*) - (b, x^*)$$

故对一切 $x \in R^n$, 有

$$\begin{aligned} \varphi(x) - \varphi(x^*) &= \frac{1}{2}(Ax, x) - (b, x) + \frac{1}{2}(Ax^*, x^*) \\ &= \frac{1}{2}(Ax, x) - (Ax^*, x) + \frac{1}{2}(Ax^*, x^*) \\ &= \frac{1}{2}(A(x - x^*), x - x^*) \end{aligned}$$

定理1 设 A 为 n 阶实对称正定矩阵, 则 x^* 为线性方程组 $Ax=b$ 的解的充要条件是: x^* 是二次函数 $\varphi(x)$ 的极小值点, 即

$$x^* = A^{-1}b \Leftrightarrow \varphi(x^*) = \min_{x \in R^n} \varphi(x)$$

其中 $\varphi(x) = \frac{1}{2}(Ax, x) - (b, x)$

证明: 《必要性》 设 x^* 是 $Ax=b$ 的解, 即 $x^*=A^{-1}b$

由性质(3), 对任意 $x \in R^n$, 都有

$$\varphi(x) - \varphi(x^*) = \frac{1}{2}(A(x - x^*), x - x^*)$$

因为 A 正定, 故 $\varphi(x) - \varphi(x^*) \geq 0$

$\varphi(x) \geq \varphi(x^*)$ 故 x^* 是 $\varphi(x)$ 的极小值点.

《充分性》 设 x^* 是 $\varphi(x)$ 的极小值点, 则由性质 (1)

$$\nabla \varphi(x) = \text{grad } \varphi(x) = Ax - b$$

可得 $\text{grad } \varphi(x) \Big|_{x=x^*} = Ax^* - b = 0,$

故 x^* 为线性方程组 $Ax=b$ 的解.

求二次函数 $\varphi(x)$ 极小值点的一般方法是：

构造一个向量序列 $\{x^{(k)}\}$ ，使 $\varphi(x^{(k)}) \rightarrow \min \varphi(x)$

可以采取以下方法：

(1) 任取一个初始向量 $x^{(0)}$ ，

(2) 构造迭代格式

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}, \quad (k = 0, 1, \dots)$$

其中 $p^{(k)}$ 是搜索方向， α_k 是搜索步长，

(3) 选择 $p^{(k)}$ 和 α_k 使得

$$\varphi(x^{(k+1)}) = \varphi(x^{(k)} + \alpha_k p^{(k)}) < \varphi(x^{(k)})$$

则当 $k \rightarrow \infty$ 时，有 $\varphi(x^{(k)}) \rightarrow \varphi(x^*) = \min_{x \in R^n} \varphi(x)$

(4) 给出误差限 ε ，直到

$$\|x^{(k)} - x^{(k-1)}\| < \varepsilon \text{ 或 } \|r^{(k)}\| = \|b - Ax^{(k)}\| < \varepsilon$$

迭代终止.

对迭代格式

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}, \quad (k = 0, 1, \dots)$$

关键是要确定搜索方向 $p^{(k)}$ 和搜索步长 α_k .

(1) 确定搜索方向 $p^{(k)}$

最速下降法： $p^{(k)}$ 取为模函数 $\varphi(x)$ 减少最快的方向，

即： $\varphi(x)$ 负梯度方向 $-\text{grad}(\varphi(x))$.

共轭梯度法：取 A -共轭方向 $p^{(k)}$.

(2) 确定搜索步长 α_k

确定 α_k 使得从 k 步到 $k+1$ 步是最优的，即：

$$\varphi(x^{(k+1)}) = \varphi(x^{(k)} + \alpha_k p^{(k)}) = \min_{\alpha} \varphi(x^{(k)} + \alpha p^{(k)})$$

这称为沿 $p^{(k)}$ 方向的一维极小搜索。 $\varphi(x^{(k+1)})$ 是局部极小.

对确定的搜索方向 $p^{(k)}$ ，构造一个关于 α 的函数

$$\begin{aligned} F(\alpha) &= \varphi(x^{(k+1)}) = \varphi(x^{(k)} + \alpha p^{(k)}) \\ &= \frac{1}{2}(A(x^{(k)} + \alpha p^{(k)}), x^{(k)} + \alpha p^{(k)}) - (b, x^{(k)} + \alpha p^{(k)}) \\ &= \frac{1}{2}(Ax^{(k)}, x^{(k)}) - (b, x^{(k)}) + \alpha(Ax^{(k)}, p^{(k)}) - \alpha(b, p^{(k)}) \\ &\quad + \frac{\alpha^2}{2}(Ap^{(k)}, p^{(k)}) \\ &= \varphi(x^{(k)}) + \alpha(Ax^{(k)} - b, p^{(k)}) + \frac{\alpha^2}{2}(Ap^{(k)}, p^{(k)}) \\ &= \varphi(x^{(k)}) - \alpha(r^{(k)}, p^{(k)}) + \frac{\alpha^2}{2}(Ap^{(k)}, p^{(k)}) \\ F'(\alpha) &= -(r^{(k)}, p^{(k)}) + \alpha(Ap^{(k)}, p^{(k)}) \end{aligned}$$

$$F'(\alpha) = -(r^{(k)}, p^{(k)}) + \alpha(Ap^{(k)}, p^{(k)})$$

$$\text{令 } F'(\alpha) = 0, \text{ 即: } -(r^{(k)}, p^{(k)}) + \alpha(Ap^{(k)}, p^{(k)}) = 0$$

$$\text{得 } \alpha = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$\because F''(\alpha) = (Ap^{(k)}, p^{(k)}) > 0, \quad (A \text{ 正定})$$

$$\text{取 } \alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}, \quad \alpha_k \text{ 是 } \varphi(x^{(k)} + \alpha p^{(k)}) \text{ 下降的极小值点,}$$

即 α_k 是 $k \rightarrow k+1$ 步的最优步长.

下面介绍几种常用的极小化方法的算法.


(一) 最速下降法

最速下降法：取模函数 $\varphi(x)$ 减少最快的方向，
即： $\varphi(x)$ 的负梯度方向 $-\text{grad}(\varphi(x))$,

$$p^{(k)} = -\text{grad}(\varphi(x^{(k)})) = r^{(k)}$$

从 $x^{(0)}$ 出发寻找 $\varphi(x)$ 的极小值点： $\varphi(x) = \varphi(x^{(0)})$ 是 $\varphi(x)$ 的等值面，因为 A 正定，它是 n 维空间的一个椭球面，从 $x^{(0)}$ 出发先找一个使 $\varphi(x)$ 减小最快的方向，这就是正交于椭球面的 $\varphi(x)$ 负梯度方向 $-\nabla\varphi(x^{(0)})$.

目标函数为二次函数，其等值面为椭球面。



注：最速下降方向反映了目标函数的一种局部性质。
它只是局部目标函数值下降最快的方向。

最速下降法是线性收敛的算法。

最速下降算法:

(1) 选取 $x^{(0)} \in R^n$

(2) 对 $k = 0, 1, 2, \dots$

$$r^{(k)} = b - Ax^{(k)}$$

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})}$$

$$\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k r^{(k)}$$

(3) 当 $\|x^{(k+1)} - x^{(k)}\| < \varepsilon$ 时, 终止迭代.

关于最速下降法，有以下两个结论：

(1) 最速下降法中相邻两次的搜索方向是正交的，即

$$(r^{(k+1)}, r^{(k)}) = 0 \quad (6)$$

$$\begin{aligned} \text{证：} \quad (r^{(k+1)}, r^{(k)}) &= (b - Ax^{(k+1)}, r^{(k)}) \\ &= (b - A(x^{(k)} + \alpha_k r^{(k)}), r^{(k)}) \\ &= (b - Ax^{(k)} - \alpha_k Ar^{(k)}, r^{(k)}) \\ &= (r^{(k)} - \alpha_k Ar^{(k)}, r^{(k)}) \\ &= (r^{(k)}, r^{(k)}) - \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})} (Ar^{(k)}, r^{(k)}) \\ &= 0 \end{aligned}$$

(2) $\{\varphi(x^{(k)})\}$ 是单调下降有界序列, 它存在极限,

可以证明 $\lim_{k \rightarrow \infty} x^{(k)} = x^* = A^{-1}b$

而且 $\|x^{(k)} - x^*\|_A \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \|x^{(0)} - x^*\|_A$

其中 λ_1, λ_n 分别是对称正定矩阵 A 的最大、最小特征值,

范数 $\|\cdot\|_A$ 定义为 $\|u\|_A = (Au, u)^{1/2}$

当 $\lambda_1 \gg \lambda_n$ 时, 收敛是很慢的,

当 $\|r^{(k)}\|$ 很小时, 因舍入误差的影响, 计算将出现不稳定现象.

例 用最速下降法解方程组

$$\begin{bmatrix} 2 & 2 \\ 2 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \end{bmatrix}$$

方程组的精确解为 $x=(4, -1)^T$.

解 系数矩阵 A 对称正定, 取 $x^{(0)}=(0,0)^T$, 有

$$r^{(0)} = b - Ax^{(0)} = (6, 3)^T$$

$$\alpha_0 = \frac{(r^{(0)}, r^{(0)})}{(Ar^{(0)}, r^{(0)})} = \frac{5}{21}$$

第一步的迭代结果为

$$x^{(1)} = x^{(0)} + \alpha_0 r^{(0)} = \begin{pmatrix} \frac{10}{7} \\ \frac{5}{7} \end{pmatrix}$$

$$r^{(1)} = b - Ax^{(1)} = \begin{pmatrix} \frac{12}{7} \\ -\frac{24}{7} \end{pmatrix}$$

$$\alpha_1 = \frac{(r^{(1)}, r^{(1)})}{(Ar^{(1)}, r^{(1)})} = \frac{45}{126}$$

第二步的迭代结果为

$$x^{(2)} = x^{(1)} + \alpha_1 p^{(1)} = \begin{pmatrix} 2.0408 \\ -0.5102 \end{pmatrix}$$

继续迭代下去，即可求得方程组的解。

(二) 共轭梯度法 (CG) (共轭斜量法)

设按方向 $p^{(0)}, p^{(1)}, \dots, p^{(k-1)}$ 已进行 k 次一维搜索, 求得 $x^{(k)}$, 下一步就是确定 $p^{(k)}$, 再求解一维极小化问题

$$\min_{\alpha} \varphi(x^{(k)} + \alpha p^{(k)})$$

可得
$$\alpha = \alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})} \quad (7)$$

下一个近似解和对应的剩余向量是

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)} \quad (8)$$

$$r^{(k+1)} = b - Ax^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)} \quad (9)$$

不失一般性地设 $x^{(0)}=0$, 反复利用(8)有

$$x^{(k+1)} = \alpha_0 p^{(0)} + \alpha_1 p^{(1)} + \dots + \alpha_k p^{(k)}$$

现在考虑 $p^{(0)}, p^{(1)}, \dots$ 取什么方向.

设 $p^{(0)}=r^{(0)}$, 一般 $k \geq 1$ 时 $p^{(k)}$ 的确定, 我们不但希望使

$$\varphi(x^{(k+1)}) = \min_{\alpha} \varphi(x^{(k)} + \alpha p^{(k)}) \quad (10)$$

而且希望 $\{p^{(k)}\}$ 的选择使

$$\varphi(x^{(k+1)}) = \min_{x \in \text{span}\{p^{(0)}, \dots, p^{(k)}\}} \varphi(x) \quad (11)$$

若 $x \in \text{span}\{p^{(0)}, \dots, p^{(k)}\}$, 可记成

$$x = y + \alpha p^{(k)}, \quad y \in \text{span}\{p^{(0)}, \dots, p^{(k-1)}\}, \quad \alpha \in R$$

所以有

$$\varphi(x) = \varphi(y + \alpha p^{(k)})$$

$$\varphi(x) = \frac{1}{2} (Ax, x) - (b, x)$$

$$= \varphi(y) + \alpha(Ay, p^{(k)}) - \alpha(b, p^{(k)}) + \frac{\alpha^2}{2} (Ap^{(k)}, p^{(k)}) \quad (12)$$

$$\text{令} \quad (Ay, p^{(k)}) = 0, \quad y \in \text{span}\{p^{(0)}, \dots, p^{(k-1)}\}$$

$$\text{即} \quad (Ap^{(j)}, p^{(k)}) = 0, \quad j = 0, 1, \dots, k-1$$

如果 $k = 1, 2, \dots$, 每步都如此选择 $p^{(k)}$, 则它们符合下面定义.

定义 A 对称正定, 若 R^n 中向量组 $\{p^{(0)}, \dots, p^{(l)}\}$ 满足

$$(Ap^{(i)}, p^{(j)}) = 0, \quad i \neq j$$

则称它为 R^n 中的一个 A -共轭向量组, 或称 A -正交向量组.

注:

- 1、当 $n > 1$ 时, 不含零向量的 A -共轭向量组线性无关;
- 2、当 $A = I$ 时, A -共轭性质就是一般的正交性;
- 3、给了一组线性无关的向量, 可以按 Schmidt 正交化的方法得到对应的 A -共轭向量组.

由 (12) $\varphi(x) = \varphi(y + \alpha p^{(k)}) = \varphi(y) - \alpha(b, p^{(k)}) + \frac{\alpha^2}{2}(Ap^{(k)}, p^{(k)})$

将极小问题(11)分离为两个极小问题:

$$\varphi(x^{(k+1)}) = \min_{x \in \text{span}\{p^{(0)}, \dots, p^{(k)}\}} \varphi(x)$$

$$\begin{aligned} \min_{x \in \text{span}\{p^{(0)}, \dots, p^{(k)}\}} \varphi(x) &= \min_{\alpha, y} \varphi(y + \alpha p^{(k)}) \\ &= \min_{y \in \text{span}\{p^{(0)}, \dots, p^{(k-1)}\}} \varphi(y) + \min_{\alpha} \left[\frac{\alpha^2}{2}(Ap^{(k)}, p^{(k)}) - \alpha(b, p^{(k)}) \right] \end{aligned}$$

第一个问题的解为 $x^{(k)}$,

第二个问题的解为 $\alpha = \alpha_k = \frac{(b, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$.

$\because x^{(k)} \in \text{span}\{p^{(0)}, \dots, p^{(k-1)}\}$, 故 $(Ax^{(k)}, p^{(k)}) = 0$,

$\because (b, p^{(k)}) = (b - Ax^{(k)}, p^{(k)}) = (r^{(k)}, p^{(k)})$

$\therefore \alpha = \alpha_k = \frac{(b, p^{(k)})}{(Ap^{(k)}, p^{(k)})} = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$ 与 (7) 相同

计算 $p^{(k)}$ ：

取 $p^{(0)}=r^{(0)}$ ， $p^{(k)}$ 就取为与 $p^{(0)}, \dots, p^{(k-1)}$ A -共轭的向量，

这样的向量不是唯一的，CG法中取 $p^{(k)}$ 为 $r^{(k)}$ 与 $p^{(k-1)}$ 的线性

组合，设
$$p^{(k)} = r^{(k)} + \beta_{k-1} p^{(k-1)} \quad (13)$$

$$\begin{aligned} \text{利用} (p^{(k)}, Ap^{(k-1)}) &= (r^{(k)} + \beta_{k-1} p^{(k-1)}, Ap^{(k-1)}) \\ &= (r^{(k)}, Ap^{(k-1)}) + \beta_{k-1} (p^{(k-1)}, Ap^{(k-1)}) = 0, \end{aligned}$$

$$\text{可得} \beta_{k-1} = -\frac{(r^{(k)}, Ap^{(k-1)})}{(p^{(k-1)}, Ap^{(k-1)})} \quad (14)$$

可以证明这样得到的向量序列 $\{p^{(k)}\}$ 是一个 A -共轭向量组。

公式化简:

由(9)式 $r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}$ 和 (7) 式 $\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$

有 $(r^{(k+1)}, p^{(k)}) = (r^{(k)}, p^{(k)}) - \alpha_k (Ap^{(k)}, p^{(k)}) = 0$

$$(r^{(k)}, p^{(k)}) = (r^{(k)}, r^{(k)} + \beta_{k-1} p^{(k-1)}) = (r^{(k)}, r^{(k)}) \quad (15)$$

$$\text{代回(7)有 } \alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})} = \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})} \quad (16)$$

当 $r^{(k)} \neq 0$ 时, $\alpha_k > 0$.

定理 由(7)——(16)定义的算法有如下性质:

(1) $(r^{(i)}, r^{(j)}) = 0, i \neq j$, 即剩余向量构成一个正交向量组.

(2) $(Ap^{(i)}, p^{(j)}) = (p^{(i)}, Ap^{(j)}) = 0, i \neq j$.

即 $\{p^{(k)}\}$ 为一个 A -共轭向量组.

还可简化 β_k 的计算:

由前 (14) 式
$$\beta_{k-1} = -\frac{(r^{(k)}, Ap^{(k-1)})}{(p^{(k-1)}, Ap^{(k-1)})} \quad (14)$$

前 (9) 式
$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)} \quad (9)$$

及前 (16) 式
$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})} \quad (16)$$

得

$$\begin{aligned} \beta_k &= -\frac{(r^{(k+1)}, Ap^{(k)})}{(p^{(k)}, Ap^{(k)})} = -\frac{(r^{(k+1)}, (\alpha_k)^{-1}(r^{(k)} - r^{(k+1)}))}{(p^{(k)}, Ap^{(k)})} \\ &= \frac{(r^{(k+1)}, r^{(k+1)})}{\alpha_k (p^{(k)}, Ap^{(k)})} = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})} \end{aligned}$$

CG算法：

(1) $x^{(0)} \in R^{(n)}$

(2) $r^{(0)} = b - Ax^{(0)}, p^{(0)} = r^{(0)}$

(3) $k = 0, 1, \dots,$

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)},$$

$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)},$$

$$\beta_k = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})}$$

$$p^{(k+1)} = r^{(k+1)} + \beta_k p^{(k)}$$

在计算过程中，若遇 $r^{(k)} = 0$ ，或
 $(p^{(k)}, Ap^{(k)}) = 0$ 时，计算终止，
 $x^{(k)} = x^*$ 。

例 用CG方法解方程组

$$\begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}$$

解 系数矩阵 A 对称正定, 取 $x^{(0)}=(0,0)^T$, 有

$$r^{(0)} = p^{(0)} = b - Ax^{(0)} = (5, 5)^T$$

$$\alpha_0 = \frac{(r^{(0)}, r^{(0)})}{(Ap^{(0)}, p^{(0)})} = \frac{2}{7}$$

$$x^{(1)} = x^{(0)} + \alpha_0 p^{(0)} = \left(\frac{10}{7}, \frac{10}{7}\right)^T$$

$$r^{(1)} = r^{(0)} - \alpha_0 Ap^{(0)} = \left(-\frac{5}{7}, \frac{5}{7}\right)^T$$

$$\beta_0 = \frac{(r^{(1)}, r^{(1)})}{(r^{(0)}, r^{(0)})} = \frac{1}{49}$$

$$p^{(1)} = r^{(1)} + \beta_0 p^{(0)} = \left(-\frac{30}{49}, \frac{40}{49}\right)^T$$

$$\alpha_1 = \frac{(r^{(1)}, r^{(1)})}{(Ap^{(1)}, p^{(1)})} = \frac{7}{10}$$

$$x^{(2)} = x^{(1)} + \alpha_1 p^{(1)} = (1, 2)^T$$

$$r^{(2)} = r^{(1)} - \alpha_1 Ap^{(1)} = (0, 0)^T$$

故方程组的解为 $x=(1,2)^T$.

注:

(1) 剩余向量相互正交, 而 R^n 中至多有 n 个相互正交的非零向量, 所以 $r^{(0)}, r^{(1)}, \dots, r^{(n)}$ 中至少有一个向量为零. 若 $r^{(k)}=0$, 则 $x^{(k)} = x^*$.

(2) 实际计算中, 由于舍入误差的影响, n 步内得不到准确解, 故还需继续迭代. 一般因 $p^{(0)}, p^{(1)}, \dots, p^{(n-1)}$ 是一组 A -共轭向量组, 继续迭代时, 要取 $x^{(0)} = x^{(n)}$.

(3) 由误差估计式

$$\|x^{(k)} - x^*\|_A \leq 2 \left[\frac{\sqrt{\text{cond}(A)_2} - 1}{\sqrt{\text{cond}(A)_2} + 1} \right]^k \|x^{(0)} - x^*\|_A$$

当 A 的条件数很小时, 共轭梯度法收敛很快, 但当 A 是病态严重的矩阵时, 共轭梯度法收敛速度很慢. 可采用预处理技术, 降低 A 的条件数.

(三) 预条件共轭梯度法(PCG)

寻找一个非奇异矩阵 C , 使 $\bar{A} = C^{-1}AC^{-T}$ 的条件数比原系数矩阵 A 的条件数得到改善.

$$Ax = b \Leftrightarrow C^{-1}AC^{-T}C^Tx = C^{-1}b \Leftrightarrow \bar{A}\bar{x} = \bar{b}$$

$$\text{其中 } \bar{A} = C^{-1}AC^{-T}, \bar{b} = C^{-1}b, \bar{x} = C^Tx,$$

令 $M=CC^T$ 称为预优矩阵, 当 M 接近 A 时, $\bar{A}$ 接近单位阵, $\text{cond}(\bar{A})_2$ 接近1, 对 $\bar{A}\bar{x} = \bar{b}$ 用共轭梯度法求解, 可达到加速的目的.

$$M = CC^T \approx A,$$

$$\bar{A} = C^{-1}AC^{-T} \approx C^{-1}MC^{-T} = C^{-1}CC^TC^{-T} = I, \text{cond}(\bar{A})_2 \approx 1$$

预条件共轭梯度法

1、计算 $\bar{A} = C^{-1}AC^{-T}, \bar{b} = C^{-1}b$

2、解 $\bar{A}\bar{x} = \bar{b}$, 得 $\bar{x}^{(k)}$,

$$(1) \bar{x}^{(0)} \in R^{(n)}$$

$$(2) \bar{r}^{(0)} = \bar{b} - \bar{A}\bar{x}^{(0)}, \bar{p}^{(0)} = \bar{r}^{(0)}$$

$$(3) k = 0, 1, \dots,$$

$$\bar{\alpha}_k = \frac{(\bar{r}^{(k)}, \bar{r}^{(k)})}{(\bar{A}\bar{p}^{(k)}, \bar{p}^{(k)})}$$

$$\bar{x}^{(k+1)} = \bar{x}^{(k)} + \bar{\alpha}_k \bar{p}^{(k)},$$

$$\bar{r}^{(k+1)} = \bar{r}^{(k)} - \bar{\alpha}_k \bar{A}\bar{p}^{(k)},$$

$$\bar{\beta}_k = \frac{(\bar{r}^{(k+1)}, \bar{r}^{(k+1)})}{(\bar{r}^{(k)}, \bar{r}^{(k)})}$$

$$\bar{p}^{(k+1)} = \bar{r}^{(k+1)} + \bar{\beta}_k \bar{p}^{(k)}$$

$$3、\bar{x}^{(k)} = C^{-T} \bar{x}^{(k)}.$$

实际计算，可通过
变换，转化成用原方
程组的量来计算。

PCG算法：

(1)取初值 $x^{(0)} \in R^{(n)}, r^{(0)} = b - Ax^{(0)},$

(2)解方程组 $Mz^{(0)} = r^{(0)},$ 求出 $z^{(0)},$ 令 $p^{(0)} = z^{(0)}$

(3) $k = 0, 1, \dots,$

$$\alpha_k = \frac{(z^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$$

$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}$$

解方程组 $Mz^{(k+1)} = r^{(k+1)}$

$$\beta_k = \frac{(z^{(k+1)}, r^{(k+1)})}{(z^{(k)}, r^{(k)})}$$

$$p^{(k+1)} = z^{(k+1)} + \beta_k p^{(k)}$$

(4)直到 $\|r^{(k+1)}\| < \varepsilon,$ 输出 $x^{(k+1)}.$

预优矩阵的选取:

预优矩阵 $M = CC^T$ 应满足:

- (1) M 是对称正定的矩阵;
- (2) 方程组 $Mz^{(k)} = r^{(k)}$ 容易求解.

下面介绍几种选取预优矩阵的方案:

- (1) A 是大型稀疏对称正定的矩阵, 取

$$M = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$$

- (2) 取 A 的三条对角线构成的三对角阵

$$M = \begin{bmatrix} a_{11} & a_{12} & & & \\ a_{21} & a_{22} & \ddots & & \\ & \ddots & \ddots & & \\ & & & a_{n-1,n} & \\ & & & a_{n,n-1} & a_{nn} \end{bmatrix}$$

(3) M 取为SSOR迭代法的预处理阵, $M = CC^T$

$$C = [\omega(2 - \omega)]^{-1/2} (D - \omega L) D^{-1/2}$$

$$C^T = [\omega(2 - \omega)]^{-1/2} D^{-1/2} (D - \omega L^T)$$

(4) M 取为块Jacobi迭代的块对角阵,

$$A = \begin{bmatrix} A_{11} & A_{12} & & \\ A_{21} & A_{22} & \ddots & \\ & \ddots & \ddots & A_{n-1,n} \\ & & A_{n,n-1} & A_{nn} \end{bmatrix},$$

$$M = \begin{bmatrix} A_{11} & & & \\ & A_{22} & & \\ & & \ddots & \\ & & & A_{nn} \end{bmatrix}$$

(5) 不完全Cholesky分解的预优矩阵

不完全Cholesky分解就是将 A 分解成

$$A = LL^T + R$$

其中 L 是下三角阵， R 称为剩余矩阵。

取 $M = LL^T$

例： $A = \begin{bmatrix} 3 & -1 & 0 & 2 \\ -1 & 3 & -1 & 0 \\ 0 & -1 & 3 & -1 \\ 2 & 0 & -1 & 3 \end{bmatrix},$

$$A = LL^T + R, \text{ 调节 } R \text{ 使 } L = \begin{bmatrix} * & & & \\ * & * & & \\ 0 & * & * & \\ * & 0 & * & * \end{bmatrix}$$

$$A = LL^T + R$$

$$L = \begin{bmatrix} \sqrt{3} & & & \\ -1/\sqrt{3} & 4/\sqrt{3} & & \\ 0 & -\sqrt{3}/4 & \sqrt{21}/4 & \\ 2/\sqrt{3} & 0 & -4/\sqrt{21} & 3/\sqrt{7} \end{bmatrix}$$

$$R = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2/3 \\ 0 & 0 & 0 & 0 \\ 0 & 2/3 & 0 & 0 \end{bmatrix}$$

预条件共轭梯度法MATLAB的三种调用格式:

1.不用预优矩阵的共轭梯度法

`x=pcg(a,b,tol,kmax)`

2.用预优矩阵的共轭梯度法

(1)`x=pcg(a,b,tol,kmax,m)`

(2) `r=chol(m)`

`x=pcg(a,b,tol,kmax,r',r,x0)`

3.未给定预优矩阵的共轭梯度法

`r=cholinc(sa,'0')`

`x=pcg(a,b,tol,kmax,r',r,x0)`

THE

END