

第四章 矩阵特征值与特征向量的计算

第四章 矩阵特征值与特征向量的计算

- 引言
- 幂法
- 反幂法

4.1 引言

定义 设 A 是 n 阶矩阵, 如果存在数 λ 和 n 维非零向量 α , 使

$$A\alpha = \lambda\alpha$$

则称 λ 为方阵 A 的一个特征值, α 为方阵 A 对应于特征值 λ 的一个特征向量.

1° A 的特征值 λ 由它的特征方程 $\varphi(\lambda) = \det(\lambda I - A) = 0$ 的根确定.

2° 设 λ 为 A 的特征值, 求齐次线性方程组 $(\lambda I - A)x = 0$ 的非零解, 便得到 A 的属于 λ 的特征向量.

设 $A\alpha = \lambda\alpha$ ($\alpha \neq 0$), 则 $(\lambda I - A)\alpha = 0$.

α 是 $(\lambda I - A)X = 0$ 的非零解.

求 A 的特征值与特征向量的步骤如下:

(1) 求 $|\lambda I - A| = 0$ 的根: $\lambda_1, \lambda_2, \dots, \lambda_k$;

(2) 求 $(\lambda_i I - A)X = 0$ 的基础解系:

$$\alpha_{i_1}, \alpha_{i_2}, \dots, \alpha_{i_{r_i}},$$

则 A 对应于 λ_i 的特征向量为:

$$k_1 \alpha_{i_1} + k_2 \alpha_{i_2} + \dots + k_{r_i} \alpha_{i_{r_i}} \quad (k_1, k_2, \dots, k_{r_i} \text{ 不全为零}).$$

回顾几个基本结论:

定理1 若 $\lambda_i(i=1,2,\dots,n)$ 为 A 的特征值, 则有

$$(1) \quad \sum_{i=1}^n \lambda_i = \sum_{i=1}^n \alpha_{ii} = \text{tr}(A)$$

$$(2) \quad \det(A) = \lambda_1 \lambda_2 \dots \lambda_n$$

定理2 设 A 与 B 为相似矩阵, 即存在可逆矩阵 P , 使得 $P^{-1}AP=B$, 则

(1) A 与 B 有相同的特征值;

(2) 若 x 为 B 的一个特征向量, 则 Px 为 A 的特征向量.

定理3 (Gerschgorin's定理) 设 $A=(a_{ij})_{n \times n}$, 则 A 的每一个特征值, 必属于下述某个圆盘之中:

$$|\lambda - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, \quad (i = 1, \dots, n)$$

且如果一个特征向量的第 i 个分量绝对值最大, 则对应的特征值一定属于第 i 个圆盘中.

例1 估计方阵特征值的范围

$$A = \begin{bmatrix} 1 & 0.1 & 0.2 & 0.3 \\ 0.5 & 3 & 0.1 & 0.2 \\ 1 & 0.3 & -1 & 0.5 \\ 0.2 & -0.3 & -0.1 & -4 \end{bmatrix}$$


解:

$$G_1 = \{z: |z - 1| \leq 0.6\};$$

$$G_2 = \{z: |z - 3| \leq 0.8\};$$

$$G_3 = \{z: |z + 1| \leq 1.8\};$$

$$G_4 = \{z: |z + 4| \leq 0.6\}.$$



注: 定理称 A 的 n 个特征值全落在 n 个盖氏圆上, 但未说明每个圆盘内都有一个特征值.

4.2 幂法

用于求矩阵的按模最大的特征值与相应的特征向量的近似值.

设 A 为 n 阶实矩阵,

λ_i, u_i ($i = 1, 2, \dots, n$)为 A 的特征值和相应的特征向量,

且满足: $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$

$u_1, u_2, \dots, u_n$, 线性无关.

幂法: 求 λ_1 及其对应的特征向量.

λ_1 通常称为主特征值.

幂法基本思想:

给定初始非零向量 $\mathbf{x}^{(0)}$, 由矩阵 A 构造一向量序列

$$\begin{cases} \mathbf{x}^{(1)} = A\mathbf{x}^{(0)} \\ \mathbf{x}^{(2)} = A\mathbf{x}^{(1)} = A^2\mathbf{x}^{(0)} \\ \dots \\ \mathbf{x}^{(k+1)} = A\mathbf{x}^{(k)} = A^{k+1}\mathbf{x}^{(0)} \\ \dots \end{cases}$$

在一定条件下, 当 k 充分大时: $\lambda_1 \approx \frac{x_i^{(k+1)}}{x_i^{(k)}}$

相应的特征向量为: $\mathbf{x}^{(k+1)}$

幂法的理论依据:

对任意非零向量 $x^{(0)}$, 有 $x^{(0)} = \sum_{i=1}^n t_i u_i$, 设 t_1 不为零.

$$x^{(k+1)} = Ax^{(k)} = A^{k+1}x^{(0)}$$

$$= \sum_{i=1}^n A^{k+1} t_i u_i = \sum_{i=1}^n t_i \lambda_i^{k+1} u_i$$

$$= \lambda_1^{k+1} \left[t_1 u_1 + \left(\frac{\lambda_2}{\lambda_1} \right)^{k+1} t_2 u_2 + \cdots + \left(\frac{\lambda_n}{\lambda_1} \right)^{k+1} t_n u_n \right]$$

$$\approx \lambda_1^{k+1} t_1 u_1$$

故 $\lambda_1 \approx x_i^{(k+1)} / x_i^{(k)}$

$x^{(k+1)}$ 为 λ_1 的特征向量的近似向量(除一个因子外).

● 如果 $x^{(0)}$ 的选取恰恰使得 $t_1=0$, 幂法仍能进行. 因为计算过程中会有舍入误差, 迭代若干次后, 必然会产生一个向量 $x^{(k)}$, 它在 u_1 方向上的分量不为零, 这样以后的计算就满足所设条件.

● 因为 $x^{(k)} \approx \lambda_1^k t_1 u_1$, 计算过程中可能会出现上溢 ($|\lambda_1| > 1$) 或下溢成为 0 ($|\lambda_1| < 1$). 为避免出现这一情形, 实际计算时每次迭代所求的向量都要归一化.

归一化过程:

设有一向量 $x \neq 0$, 将其归一化得到向量

$$y = \frac{x}{\max(x)}$$

其中 $\max(x)$ 表示向量 x 的绝对值最大的分量, 即如果有

$$|x_{i_0}| = \max_{1 \leq i \leq n} |x_i|$$

则 $\max(x) = x_{i_0}$, 且 i_0 为所有绝对值最大的分量中的最小下标.

例 $x = (1, -8, 7)^T$, 则 $\max(x) = -8$, 归一化向量为

$$y = \frac{x}{\max(x)} = (-0.125, 1, -0.875)^T$$

幂法的计算公式:

任取初始向量 $x^{(0)}=y^{(0)}\neq 0$, 对 $k=1, 2, \dots$, 构造向量序列 $\{x^{(k)}\}, \{y^{(k)}\}$

$$\begin{cases} x^{(k)} = Ay^{(k-1)} \\ \alpha_k = \max(x^{(k)}) \\ y^{(k)} = \frac{x^{(k)}}{\alpha_k} \end{cases}$$

当 k 充分大时, $\alpha_k \approx \lambda_1, y^{(k)} \approx \frac{u_1}{\max(u_1)}$

算法1：（幂法）

1. 输入 A , 初始向量 x , 误差限 ε , 最大迭代次数 N ;
2. 置 $k = 1, \lambda = 0; y = \frac{x}{\max(x)}$;
3. 计算 $x = Ay, \quad \alpha = \max(x), \quad y = \frac{x}{\alpha}$;
4. 若 $|\lambda - \alpha| < \varepsilon$, 输出 α, y , 程序终止; 否则, 转5;
5. 若 $k < N$, 置 $k = k + 1, \lambda = \alpha$, 转3 ;
否则输出失败信息, 程序终止.

例 用幂法求矩阵 $A = \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$

的按模最大的特征值.

取 $x^{(0)} = (0, 0, 1)^T$, 要求误差不超过 10^{-3} .

解 $y^{(0)} = x^{(0)} = (0, 0, 1)^T,$

$$x^{(1)} = Ay^{(0)} = (0, -1, 2)^T, \quad \alpha_1 = \max(x^{(1)}) = 2,$$

$$y^{(1)} = \frac{x^{(1)}}{\alpha_1} = (0, -0.5, 1)^T$$

$$x^{(2)} = Ay^{(1)} = (0.5, -2, 2.5)^T, \quad \alpha_2 = \max(x^{(2)}) = 2.5,$$

$$y^{(2)} = \frac{x^{(2)}}{\alpha_2} = (0.2, -0.8, 1)^T$$

$$x^{(3)} = Ay^{(2)} = (1.2, -2.6, 2.8)^T, \quad \alpha_3 = \max(x^{(3)}) = 2.8,$$

$$\alpha_4 = 2.9285714,$$

$$\alpha_5 = 2.9756097,$$

$$\alpha_6 = 2.9918619,$$

$$\alpha_7 = 2.9972799,$$

$$\alpha_8 = 2.9990924,$$

$$\alpha_9 = 2.9996973.$$

$$\therefore |\alpha_9 - \alpha_8| = |2.9996973 - 2.99909241| = 0.0006049 < 10^{-3}$$

$$\therefore \lambda_1 \approx \alpha_9 = 2.9996973.$$

幂法的适用范围：

- 幂法特别适用于求大型稀疏矩阵的主特征值和相应的特征向量.
- 幂法的收敛速度取决于比值 $|\lambda_2/\lambda_1|$, 即

$$\lim_{k \rightarrow \infty} \left| \frac{\alpha_{k+1} - \lambda_1}{\alpha_k - \lambda_1} \right| = \left| \frac{\lambda_2}{\lambda_1} \right|$$

比值越接近1, 收敛速度越慢, 比值越接近0, 收敛越快.

- 若 A 的主特征值 λ_1 为实的 m 重根, 即 $\lambda_1 = \lambda_2 = \dots = \lambda_m$, 且 $|\lambda_1| > |\lambda_{m+1}| \geq |\lambda_{m+2}| \geq \dots \geq |\lambda_n|$, 又设 A 有 n 个线性无关的特征向量, 此时幂法仍然适用.

幂法的加速:

(一) 原点移位法

λ_i 是 A 的特征值, 则 $\lambda_i - \lambda_0$ 是 $A - \lambda_0 I$ 的特征值

$$\begin{aligned} x^{(k+1)} &= (A - \lambda_0 I)x^{(k)} \\ &= (\lambda_1 - \lambda_0)^{k+1} [\alpha_1 u_1 + (\frac{\lambda_2 - \lambda_0}{\lambda_1 - \lambda_0})^{k+1} \alpha_2 u_2 + \cdots (\frac{\lambda_n - \lambda_0}{\lambda_1 - \lambda_0})^{k+1} \alpha_n u_n] \end{aligned}$$

设 A 有特征值 λ_i , 且 $|\lambda_1| > |\lambda_2| > \dots$, 取 λ_0 使得

$$|\lambda_1 - \lambda_0| > |\lambda_i - \lambda_0| \quad (i = 2, 3, \dots, n)$$

$$\text{且} \quad \frac{\max_{i \neq 1} |\lambda_i - \lambda_0|}{|\lambda_1 - \lambda_0|} < \left| \frac{\lambda_2}{\lambda_1} \right|$$

用幂法求 $A - \lambda_0 I$ 的按模最大的特征值 λ_1^* ,

则 $\lambda_1 = \lambda_1^* + \lambda_0$, 这种方法称为原点移位法.

注: 实际应用时, A 的特征值不知道, λ 无法确定,
当收敛速度慢时, 可以适当移动原点.

例

$$A = \begin{bmatrix} -4 & 14 & 0 \\ -5 & 13 & 0 \\ -1 & 0 & 2.8 \end{bmatrix}$$

矩阵 A 的特征值为 $\lambda_1 = 6$, $\lambda_2 = 3$, $\lambda_3 = 2.8$.

直接应用幂法求矩阵 A 的主特征值时,

$$r = \left| \frac{\lambda_2}{\lambda_1} \right| = \frac{1}{2}.$$

用原点移位法求主特征值, 取 $\lambda_0=2.9$, 此时

$$r = \left| \frac{\lambda_2 - \lambda_0}{\lambda_1 - \lambda_0} \right| = \frac{0.1}{3.1} = \frac{1}{31}.$$

故原点移位法的收敛速度要快得多.

(二) 幂法的埃特肯 (Aitken) 加速

若 $\{a_k\}$ 收敛于 a , 且 $\lim_{k \rightarrow \infty} \frac{a_{k+1} - a}{a_k - a} = c \neq 0$

即 $\{a_k\}$ 线性收敛, 当 k 充分大时, 有

$$\frac{a_{k+1} - a}{a_k - a} \approx \frac{a_{k+2} - a}{a_{k+1} - a}$$

$$\Rightarrow a \approx a_k - \frac{(a_{k+1} - a_k)^2}{a_{k+2} - 2a_{k+1} + a_k}$$

把上式右端记为 $\hat{a}_k$

$$\hat{a}_k = a_k - \frac{(a_{k+1} - a_k)^2}{a_{k+2} - 2a_{k+1} + a_k}$$

可以证明 $\begin{cases} \lim_{k \rightarrow \infty} \hat{a}_k = a, \\ \lim_{k \rightarrow \infty} \frac{\hat{a}_k - a}{a_k - a} = 0. \end{cases}$ 即 $\hat{a}_k \rightarrow a$ 比 $a_k \rightarrow a$ 快.

● 用 $\{\hat{a}_k\}$ 逼近 a , 这就是Aitken加速法.

● 将Aitken方法用于幂法产生的序列 $\{\alpha_k\}$, 可加快幂法的收敛速度.

算法2：（幂法加速）

1.输入 $A = (a_{ij})$, 初始向量 x , 误差限 ε , 最大迭代次数 N ,

2.置 $k = 1$, $\alpha_0 = 0$, $\alpha_1 = 0$, $\lambda_0 = 1.0$, $y = \frac{x}{\max(x)}$,

3.计算 $x = Ay$, 置 $\alpha_2 = \max(x)$, $y = \frac{x}{\max(x)}$,

4.计算 $\lambda = \alpha_0 - \frac{(\alpha_1 - \alpha_0)^2}{\alpha_2 - 2\alpha_1 + \alpha_0}$,

5.若 $|\lambda - \lambda_0| < \varepsilon$, 输出 λ, y , 程序终止, 否则转6;

6.若 $k < N$, 置 $\alpha_0 = \alpha_1$, $\alpha_1 = \alpha_2$, $\lambda_0 = \lambda$, $k = k + 1$, 转3,

否则, 输出失败信息, 程序终止.

例 用Aitken加速法求矩阵 $A = \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$

的按模最大的特征值和相应的特征向量, 取 $x^{(0)} = (0, 0, 1)^T$.

解

$$\hat{\alpha}_k = \alpha_k - \frac{(\alpha_{k+1} - \alpha_k)^2}{\alpha_{k+2} - 2\alpha_{k+1} + \alpha_k}$$

$$\alpha_1 = 2,$$

$$\alpha_2 = 2.5,$$

$$\alpha_3 = 2.8,$$

$$\alpha_4 = 2.9285714,$$

$$\alpha_5 = 2.9756097,$$

$$\alpha_6 = 2.9918619.$$

$$\hat{\alpha}_1 = 3.25,$$

$$\hat{\alpha}_2 = 3.024999,$$

$$\hat{\alpha}_3 = 3.0027472,$$

$$\hat{\alpha}_4 = 3.0004416.$$

(三) 对称矩阵的Rayleigh商加速法

定义 设 A 对称, $x \neq 0$, 则称

$$R(x) = \frac{x^T A x}{x^T x}$$

为 x 关于 A 的Rayleigh商.

公式

$$\left\{ \begin{array}{l} y^{(k)} = \frac{x^{(k)}}{\max(x^{(k)})} \\ x^{(k+1)} = Ay^{(k)} \\ R(y^{(k)}) = \frac{(y^{(k)})^T x^{(k+1)}}{(y^{(k)})^T (y^{(k)})} \end{array} \right.$$

称为Rayleigh商加速法.

其中

$$R(y^{(k)}) \rightarrow \lambda_1, y^{(k)} \rightarrow \frac{u_1}{\max(u_1)}$$

注：有了 $R(x^{(k)})$, $R(x^{(k+1)})$, $R(x^{(k+2)})$ 的值，可再用Aitken加速法得到的一个更好的近似值：

因为

$$\frac{R(x^{(k+2)}) - \lambda_1}{R(x^{(k+1)}) - \lambda_1} \approx \frac{R(x^{(k+1)}) - \lambda_1}{R(x^{(k)}) - \lambda_1}$$

所以

$$\lambda_1 \approx R(x^{(k+2)}) - \frac{[R(x^{(k+2)}) - R(x^{(k+1)})]^2}{R(x^{(k+2)}) - 2R(x^{(k+1)}) + R(x^{(k)})} = \lambda_1^{(k+2)}$$

4.3 反幂法

基本思想: $Ax = \lambda x \Rightarrow x = A^{-1}(\lambda x)$, 则 $A^{-1}x = \frac{1}{\lambda}x$

(1) A 与 A^{-1} 的特征值互为倒数, 特征向量不变,

求 A 的按模最小的特征值 λ_n

$\Leftrightarrow$ 求 A^{-1} 的按模最大的特征值 $\frac{1}{\lambda_n}$.

(2) 计算 $x^{(k+1)} = A^{-1}y^{(k)} \Leftrightarrow$ 解方程组 $Ax^{(k+1)} = y^{(k)}$

定理 设 A 为非奇异矩阵且有 n 个线性无关的特征向量，其对应的特征值满足

$$|\lambda_1| \geq |\lambda_2| \geq \cdots \geq |\lambda_{n-1}| > |\lambda_n| > 0,$$

则对任何初始非零向量 $x^{(0)}$ ($t_n \neq 0$), 由反幂法构造的向量序列 $\{x^{(k)}\}, \{y^{(k)}\}$ 满足

$$(1) \quad \lim_{k \rightarrow \infty} y^{(k)} = \frac{u_n}{\max(u_n)}$$

$$(2) \quad \lim_{k \rightarrow \infty} \max(x^{(k)}) = \frac{1}{\lambda_n}.$$

收敛速度比值为 $\left| \frac{\lambda_n}{\lambda_{n-1}} \right|.$

带原点移位的反幂法:

在反幂法中也可用原点移位法来加速迭代过程或求其他特征值及特征向量.

设已知 A 的一个特征值 λ^* 的近似值 λ , 因为 λ 接近 λ^* , 一般应有

$$0 < |\lambda^* - \lambda| \ll |\lambda_i - \lambda| \quad (\lambda_i \neq \lambda^*)$$

故 $\lambda^* - \lambda$ 是矩阵 $A - \lambda I$ 的按模最小的特征值, 比值 $|(\lambda^* - \lambda)/(\lambda_i - \lambda)|$ 较小. 因此对 $A - \lambda I$ 用反幂法求 $\lambda^* - \lambda$ 一般收敛很快, 通常只要迭代二、三次就能达到较高的精度.

原点移位反幂法:

任取初始向量 $x^{(0)}=y^{(0)}\neq 0$,

$$\begin{cases} x^{(k+1)} = (A - \lambda I)^{-1} y^{(k)} \\ y^{(k+1)} = \frac{x^{(k+1)}}{\max(x^{(k+1)})} \end{cases} \quad (k = 0, 1, 2, \dots).$$

迭代向量 $x^{(k+1)}$ 可以通过解方程组求得

$$(A - \lambda I)x^{(k+1)} = y^{(k)}$$

为了节省计算量，可以先对 $A - \lambda I$ 作三角分解

$$A - \lambda I = LU$$

已知 $y^{(k)}$ 求 $x^{(k+1)}$ 可通过下列方式进行

$$(A - \lambda I)x^{(k+1)} = y^{(k)}$$

$$\Leftrightarrow LUx^{(k+1)} = y^{(k)}$$

$$\Leftrightarrow \begin{cases} Lz^{(k+1)} = y^{(k)}, \\ Ux^{(k+1)} = z^{(k+1)}. \end{cases}$$

原点移位反幂法计算公式:

任取初始向量 $x^{(0)}=y^{(0)}\neq 0$, 先对 $A-\lambda I$ 作三角分解

$$A - \lambda I = LU$$

用下列计算公式构造向量序列 $\{x^{(k)}\}$, $\{y^{(k)}\}$

$$\left\{ \begin{array}{l} Lz^{(k+1)} = y^{(k)} \\ Ux^{(k+1)} = z^{(k+1)} \\ y^{(k+1)} = \frac{x^{(k+1)}}{\max(x^{(k+1)})} \end{array} \right. \quad (k = 0, 1, 2, \dots). \quad \left. \vphantom{\begin{array}{l} Lz^{(k+1)} = y^{(k)} \\ Ux^{(k+1)} = z^{(k+1)} \\ y^{(k+1)} = \frac{x^{(k+1)}}{\max(x^{(k+1)})} \end{array}} \right\} \text{已知 } y^{(k)} \text{ 求 } x^{(k+1)}.$$

在一定条件下，有

$$(1) \quad \lim_{k \rightarrow \infty} y^{(k)} = \frac{u}{\max(u)} \quad (\text{其中 } u \text{ 为 } \lambda^* \text{ 所对应的特征向量})$$

$$(2) \quad \lim_{k \rightarrow \infty} \max(x^{(k)}) = \frac{1}{\lambda^* - \lambda}, \text{ 即}$$

$$\lambda + \frac{1}{\max(x^{(k)})} \rightarrow \lambda^* \quad (k \rightarrow \infty)$$

算法3: (反幂法)

1. 输入矩阵 A , 近似值 λ , 初始向量 x , 误差限 ε , 最大迭代次数 N ;
2. 置 $k = 1$, $\lambda_0 = 1$, $y = \frac{x}{\max(x)}$;
3. 作三角分解 $(A - \lambda I) = LU$;
4. 解方程组 $LUx = y$ ($Lz = y, Ux = z$);
5. $\mu = \max(x)$, $y = \frac{x}{\max(x)}$, $\lambda^* = \lambda + \frac{1}{\mu}$;
6. 若 $|\lambda^* - \lambda_0| < \varepsilon$, 输出 λ^* , y , 程序终止, 否则转7;
7. 若 $k < N$, 置 $k = k + 1$, $\lambda_0 = \lambda^*$, 转4, 否则输出失败信息, 程序终止.

例：用反幂法求矩阵 $A = \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$

求按模最小的特征值及特征向量, 取 $x^{(0)} = (0, 0, 1)^T$.

解：求 A 按模最小的特征值及其特征向量

用反幂法

$$x^{(k+1)} = A^{-1}y^{(k)} \Leftrightarrow Ax^{(k+1)} = y^{(k)}$$

将 A 进行 LU 分解,

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -\frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & 0 & \frac{3}{2} \end{bmatrix} = LU$$

$$\mathbf{y}^{(0)} = \mathbf{x}^{(0)} = (0,0,1)^T$$

$$\mathbf{x}^{(1)} = A^{-1} \mathbf{y}^{(0)} \Leftrightarrow L U \mathbf{x}^{(1)} = \mathbf{y}^{(0)} \quad L = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -\frac{1}{2} & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & 0 & \frac{3}{2} \end{bmatrix}$$

$$L \mathbf{z} = \mathbf{y}^{(0)} \quad \mathbf{z} = (0,0,1)^T$$

$$U \mathbf{x}^{(1)} = \mathbf{z} \quad \mathbf{x}^{(1)} = \left(\frac{1}{6}, \frac{1}{3}, \frac{2}{3}\right)^T \quad \mu = \frac{2}{3}$$

$$\lambda^{(1)} = \frac{1}{\mu} = 1.5 \quad \mathbf{y}^{(1)} = \left(\frac{1}{4}, \frac{1}{2}, 1\right)^T$$

$$L \mathbf{z} = \mathbf{y}^{(1)} \quad \mathbf{z} = \left(\frac{1}{4}, \frac{1}{2}, \frac{5}{4}\right)^T$$

$$U \mathbf{x}^{(2)} = \mathbf{z} \quad \mathbf{x}^{(2)} = \left(\frac{11}{24}, \frac{2}{3}, \frac{5}{6}\right)^T \quad \mu = \frac{5}{6}$$

$$\lambda^{(2)} = \frac{1}{\mu} = 1.2 \quad \mathbf{y}^{(2)} = \left(\frac{11}{20}, \frac{4}{5}, 1\right)^T$$

k	lambda	y1	y2	y3	err
1.0000	1.5000	0.2500	0.5000	1.0000	1.5000
2.0000	1.2000	0.5500	0.8000	1.0000	0.3000
3.0000	1.0714	0.7589	0.9286	1.0000	0.1286
4.0000	1.0244	0.8765	0.9756	1.0000	0.0470
5.0000	1.0082	0.9378	0.9918	1.0000	0.0162
6.0000	1.0027	0.9688	0.9973	1.0000	0.0055
7.0000	1.0009	0.9844	0.9991	1.0000	0.0018
8.0000	1.0003	0.9922	0.9997	1.0000	0.0006

THE

END